

임종경

데이콘 해커톤

폐렴 X-ray 이미지 분류

실험 모델 포트폴리오

EfficientNet-B0 · ResNet18 · ResNet34 앙상블 기반 v41 최고점 모델

최종 Accuracy 0.9519230769 | 초기 제출 대비 +0.0064102564

의료 이미지 분류 · validation threshold tuning · Grad-CAM 해석



Portfolio

Pneumonia X-ray Classification

폐렴 X-ray 이미지 분류

딥러닝 기반 의료 이미지 분류 모델 개선 프로젝트

최종 제출 Accuracy

0.9519230769

초기 제출 Accuracy

0.9455128205

총 개선폭

+0.0064102564

핵심 요약

초기 제출 대비 약 4개 샘플에 해당하는 Accuracy 개선을 달성했습니다. 핵심은 학습된 모델의 예측 확률을 validation 기준으로 재해석하여 decision boundary를 개선한 점입니다.

성능 병목은 decision rule에서 확인되었습니다

기존 argmax 방식은 경계 샘플에서 유연성이 제한적이었습니다.

문제점	의미
고정 argmax	0.5 근처 probability 샘플에서 최적 boundary가 아닐 수 있음
모델별 성향 차이	EffNet, ResNet18, ResNet34가 서로 다른 특징을 포착
검증-제출 차이	validation이 좋아도 실제 제출에서 흔들릴 수 있음

목표: 테스트 라벨을 직접 수정하지 않고, train/validation 데이터 안에서 결정한 전역 규칙만으로 성능을 개선합니다.

v41은 세 모델의 probability를 전역 규칙으로 결합했습니다

최종 rule은 validation split에서 선택하고, 테스트 전체에 동일하게 적용했습니다.

$$p = 0.60 \times \text{EffNet} + 0.05 \times \text{ResNet18} + 0.35 \times \text{ResNet34}$$

$p \geq 0.509$ 이면 폐렴(1), 아니면 정상(0)

- 테스트 데이터는 추론에만 사용
- 파일별 라벨 수동 수정 없음
- 외부 데이터 미사용

실험은 데이터 누수를 방지하는 구조로 설계했습니다

테스트 이미지는 최종 추론에만 사용하고, 모든 의사결정은 train/validation 안에서 수행했습니다.

구분	설정	목적
데이터	데이콘 제공 train/test 데이터만 사용	외부 데이터 사용 방지
분리 방식	train.csv stratified split, validation ratio 0.18, seed 42	클래스 비율을 유지한 검증
입력 전처리	Resize 240×240, ImageNet mean/std normalization	ImageNet pretrained 계열 모델 입력 형식과 정합
테스트 사용	학습/검증 미사용, 제출 CSV 생성용 추론만 수행	Data leakage 방지

규칙 준수 기준: 테스트 데이터는 모델 입력으로만 사용했으며, 파일별 라벨 수동 수정은 수행하지 않았습니다.

v41은 validation에서 전역 threshold를 선택했습니다

각 테스트 파일을 개별 조정하지 않고, validation에서 선택한 하나의 규칙을 전체 테스트셋에 적용했습니다.

탐색 항목	v41 선택값	의미
앙상블 가중치	EffNet 0.60 / ResNet18 0.05 / ResNet34 0.35	모델별 probability를 보완적으로 결합
Threshold	0.509	폐렴 class probability의 decision boundary
Validation Accuracy	0.9914802982	train split 내부 검증 기준
Confusion Matrix	[[234, 7], [1, 697]]	폐렴 recall을 높게 유지하면서 정상 오분류 제한

최종 rule $p = 0.60 \times \text{EffNet} + 0.05 \times \text{ResNet18} + 0.35 \times \text{ResNet34}$, $p \geq 0.509$ 이면 폐렴(1)

초기 제출 대비 유의미한 성능 개선을 달성했습니다

초기 제출


0.9455

v40 baseline

0.9487

v41 final

0.9519



초기 제출 대비 +0.0064102564 개선되었습니다. 624개 테스트셋 기준 약 4개 샘플에 해당하는 차이로, 단순한 변동이 아니라 실험 설계 개선에 따른 유의미한 향상입니다.

추가 실험을 통해 과적합 가능성을 확인했습니다

실패 사례	결과	배운 점
v36 TTA + weight search	0.9439	복잡한 TTA가 X-ray에서 항상 유리하지 않음
v42 다른 threshold 조합	v41보다 낮음	validation 동률이어도 오류 패턴이 다르면 제출 점수가 달라짐
테스트 피드백 기반 조정	폐기	대회 규칙상 적절하지 않아 최종 산출물에서 제외

결론: validation 안에서 결정한 단순하고 일관된 전역 규칙이 가장 안정적인 결과를 보였습니다.


Grad-CAM으로 모델 판단 근거를 점검했습니다



정상 정분류
true=0 / pred=0



폐렴 정분류
true=1 / pred=1



경계/오분류
true=0 / pred=1

해석: 정분류 샘플에서는 폐 영역 또는 음영 영역에 attention이 집중되는지 확인하고, 경계 샘플에서는 촬영 각도나 심장 음영 같은 혼동 요인을 점검한다.

핵심 인사이트는 probability calibration입니다

- 성능 개선의 핵심은 새 모델 추가가 아니라 probability 해석 방식이었습니다.
- threshold 조정은 테스트 라벨을 직접 수정하지 않고 decision boundary를 개선했습니다.
- 의료 이미지에서는 Accuracy뿐 아니라 Recall, Precision, AUROC, 설명 가능성을 함께 검토해야 합니다.
- 실무 적용 시에는 K-fold validation과 calibration 안정성 검증이 필요합니다.

가장 효과적인 전략: validation 기반 global threshold 조정

다음 단계는 validation 안정성 강화입니다

다음 적용	목적
K-fold validation	단일 split 의존도를 줄이고 threshold 안정성 확인
Calibration 분석	probability가 실제 정답률과 잘 맞는지 점검
모델별 Grad-CAM 비교	앙상블 구성원이 서로 다른 영역을 보는지 확인

최종 선택: v41 Model-Only Validation Threshold Ensemble

제출 Accuracy 0.9519230769

감사합니다

폐렴 X-ray 이미지 분류 모델 개선 프로젝트

Contact

Email ljk8324@naver.com

Phone 010-6554-2523

최종 성과

v41 Model-Only Validation Threshold Ensemble

Accuracy 0.9519230769 | 초기 제출 대비 +0.0064102564

핵심 기여

- 데이터 누수 없이 validation 기반 전역 threshold를 설계했습니다.
- 세 모델의 probability를 앙상블하여 decision boundary를 개선했습니다.
- Grad-CAM으로 모델 판단 근거를 점검했습니다.