

난임 환자 대상 임신 성공 여부 예측 AI

조 이름 회사 제출 PPT

팀원 1 임종경

목차

01 데이터 탐색 (EDA)

02 데이터 전처리

03 모델링

04 평가 지표 계산

데이터 탐색 (EDA)

결측치, 이상치 확


결측치는 있으나, 큰 이상치는 없는 것으로 판단 됨
(그러나 결측치가 많이 있음!)

8 rows × 47 columns

임신 시도 또는 마지막 임신 경과 연 수	배란 자극 여부	단일 배아 이식 여부	착상 전 유전 검사 사용 여부	착상 전 유전 진단 사용 여부	남성 주 불임 원인	남성 부 불임 원인	여성 주 불임 원인	여성 부 불임 원인	부부 주 불임 원인	...	신선 배아 사용 여부	기증 배아 사용 여부	대리모 여부	PGD 기술 여부	PGS 기술 여부	난자 채취 경과 일	난자 해동 경과 일	난자 혼합 경과 일	배아 이식 경과 일	배아 해동 경과 일	
count	614.000000	15973.000000	15585.000000	151.0	15585.000000	15973.000000	15973.000000	15973.000000	15973.000000	15973.000000	...	15585.000000	15585.000000	15585.000000	138.0	107.0	12337.0	89.0	12623.000000	13277.000000	2514.000000
mean	9.135179	0.768923	0.232467	1.0	0.011870	0.028861	0.013210	0.031365	0.012834	0.033619	...	0.840103	0.009753	0.004941	1.0	1.0	0.0	0.0	0.004674	3.254500	0.036595
std	3.392675	0.421535	0.422419	0.0	0.108306	0.167422	0.114176	0.174309	0.112562	0.180253	...	0.366523	0.098277	0.070118	0.0	0.0	0.0	0.0	0.093661	1.714986	0.385074
min	3.000000	0.000000	0.000000	1.0	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	0.000000	0.000000	0.000000	1.0	1.0	0.0	0.0	0.000000	0.000000	0.000000
25%	7.000000	1.000000	0.000000	1.0	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	1.000000	0.000000	0.000000	1.0	1.0	0.0	0.0	0.000000	2.000000	0.000000
50%	8.500000	1.000000	0.000000	1.0	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	1.000000	0.000000	0.000000	1.0	1.0	0.0	0.0	0.000000	3.000000	0.000000
75%	11.000000	1.000000	0.000000	1.0	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	1.000000	0.000000	0.000000	1.0	1.0	0.0	0.0	0.000000	5.000000	0.000000
max	20.000000	1.000000	1.000000	1.0	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	...	1.000000	1.000000	1.000000	1.0	1.0	0.0	0.0	5.000000	7.000000	6.000000



변수 간 상관관계 파악



IVF 성공 예측을 위한 데이터 전처리 전략

전처리 파이프라인 개요



구조화

수치형/범주형 변수 고정 및 기초 분류 수행



정제 및 보간

결측치/Zero 플래그 생성 및 중앙값 보정




도메인 엔지니어링

IVF 지식 기반의 파생 변수 및 상호작용 추출

1. 데이터 분류 및 고정

- ✓ 기초 컬럼 복사: 원본 데이터 보존을 위한 `base_cols` 고정
- ✓ 범주형 분리: object 타입 선택 및 처리
- ✓ 수치형 분리: `exclude object` 기반 수치 데이터 필터링



2. 결측치 및 Zero 값 바이너리 플래그

`_missing` 플래그

단순 결측치 보간 전, 결측 여부 자체가 가지는 정보(데이터 누락 패턴)를
학습에 활용

`_is_zero` 플래그

수치형 데이터에서 0이 가지는 특수한 의미(예: 경험 없음)를 별도 피처로
분리

3. 체계적 결측치 처리

- A 범주형(Categorical): 모든 결측치를 'Missing'이라는 새로운 카테고리로 통일하여 불확실성 유지
- 📊 수치형(Numeric): 이상치에 강건한 Median(중앙값)을 사용하여 Train/Test 일관성 있게 보간
- 🔄 데이터 무결성: 원본의 분포를 최대한 유지하며 알고리즘 오류 방지

4. 데이터 분포 정규화 (Log1p)

수치형 변수의 왜곡(Skewness)을 방지하기 위해 로그 변환을 적용했습니다.

$$x_{\log} = \ln (1 + x)$$

효과: 변수 간 스케일 차이를 완화하고, 특히 쓸림 현상이 심한 IVF 수치 데이터의 선형성을 확보합니다.

5. 도메인 피쳐: 배아 관리

embryo_total: 총 생성, 미세주입, 저장 배아의 합계를 통해 전체 생산성을 측정합니다.

implant_ratio: 생성 대비 이식 성공 비율을 산출하여 효율성을 평가합니다.



6. 시간적 감소 요인 반영

1 / T

time_decay 피쳐

임신 시도 또는 마지막 임신 경과 연수에 따른 성공 확률의 비선형적 감소를 반영합니다.

$$f(t) = \frac{1}{t + 10^{-6}}$$

7. 환자별 행 통계량 (Aggregation)

생성 변수명	계산식	전략적 의미
row_mean	수치형 변수들의 평균	환자의 전반적인 건강/시술 지표 수준
row_std	수치형 변수들의 표준편차	지표 간의 불균형 및 변동성 측정

8. 고급 인코딩 전략



Frequency Encoding

해당 범주가 전체에서 차지하는 비율로 변환하여 중요도 학습



Label Encoding

범주형 텍스트 데이터를 수치로 변환하여 모델 연산 가능화

9. 변수 간 상호작용 (Interaction)

핵심 변수 2종에 대한 곱셈 상호작용 피처를 추가하여 복합적인 영향을 포착했습니다.



상위 중요 변수 간 시너지를 모델이 더 명확하게 인지할 수 있도록 유도합니다.

CatBoost 모델 최적화 Hyperparameter Tuning

Optuna 기반 자동 최적화 및 3-Fold Stratified CV 결과

검증 프레임워크: Stratified K-Fold

-  **균형 잡힌 검증 (3-Splits):**
타겟 변수(y)의 비율을 유지하며 데이터를 3분할하여 검증의 신뢰도 확보
-  **Early Stopping 적용:**
early_stopping_rounds=100 설정을 통해 과적합 방지 및 학습 효율 극대화
-  **평가 지표 (ROC-AUC):**
OOF(Out-of-Fold) 예측값을 기반으로 전체 AUC를 계산하여 최적화 방향 설정

Objective Function

최적화 목적 함수는 각 Trial마다 생성된 OOF 예측 성능 (Maximize AUC)을 반환하여 Optuna가 다음 파라미터를 결정하도록 유도합니다.

핵심 튜닝 파라미터 및 탐색 범위

iterations

500 ~ 1500
학습 반복 횟수 결정

learning_rate

0.01 ~ 0.1
가중치 업데이트 크기

depth

4 ~ 10
트리의 최대 깊이

l2_leaf_reg

1 ~ 10
L2 정규화 계수

random_strength

0.1 ~ 10
트리 구조의 무작위성


bagging_temp

0 ~ 10
배깅 설정 강도

* CatBoost의 강점인 범주형 변수 자동 처리를 유지하며 수치적 안정성을 위한 파라미터 중심 최적화

최적화 과정 및 성능 추이

15회의 Trial 진행 중 **Trial 12**에서 최고 성능 도출



초기 단계: 대담한 파라미터 시도로 성능 변동성이 큼

수렴 단계: 10회 이후 AUC 0.7395 이상으로 안정적으로 수렴

Best Score: **AUC 0.739675 (Trial 12)**

최종 도출된 Best Parameters

iterations1201

learning_rate0.038048

depth5

l2_leaf_reg9.980081

random_strength9.059965

bagging_temperature2.461071

결과 요약 및 분석

- **트리 깊이(Depth 5):** 너무 깊지 않은 트리를 선택하여 모델의 일반화 성능을 높였습니다.
- **학습률(0.038):** 적절한 보폭의 학습률을 통해 iterations 1200회 내외에서 최적점에 도달했습니다.
- **정규화:** 높은 L2 정규화와 Random Strength 값을 통해 복잡한 데이터셋에 대한 과적합을 효과적으로 억제했습니다.



모델링 및 평가

모델 앙상블: Stacking 기법

서로 다른 알고리즘의 강점을 결합하여 예측 성능을 극대화했습니다.

Base Models (Level 1)

- **CatBoost:** 범주형 데이터 강점
- **LightGBM:** 고속 학습 및 효율성
- **XGBoost:** 정규화를 통한 안정성

Meta Models (Level 2)

- **Logistic Regression:**
- 개별 모델의 확률 예측값을 입력으로 받아 가중치 최적화

결과:
개별 모델 대비 안정적인 AUC 0.7402 달성 (최종 리더보드: 0.74173)